

YZM212 Makine Öğrenmesi — 4. Laboratuvar Ödevi

Uzak Bir Galaksinin Parlaklık Analizi

Bayesyen Çıkarım ve MCMC ile Parametre Tahmini

1. Problem Tanımı

Astronomide bir gök cisminin gerçek parlaklığı (μ) doğrudan ölçülemez; teleskop sensöründen, atmosferden ve kozmik tozdan kaynaklanan gürültü nedeniyle yalnızca gürültülü gözlemler elde edilir. Bu ödevde, **Bayesyen Çıkarım** ve **MCMC** (Markov Chain Monte Carlo) yöntemini kullanarak sentetik olarak üretilmiş gürültülü 50 ölçümden galaksinin gerçek parlaklığını (μ) ve ölçüm gürültüsünün standart sapmasını (σ) birlikte tahmin ediyoruz. Bayesyen yaklaşım, nokta tahmini yerine parametrelere ait **olasılık dağılımları (posterior)** üretir; bu da tahminin belirsizliğini dürüstçe raporlamamızı sağlar.


Bayes Teoremi:

$$P(\theta|D) = P(D|\theta) \cdot P(\theta) / P(D)$$

Burada $P(\theta|D)$ **posterior** (veri sonrası inancımız), $P(D|\theta)$ **likelihood** (parametreler doğruysa veriyi görme olasılığı), $P(\theta)$ **prior** (önsel bilgi), $P(D)$ ise **evidence** (normalizasyon sabiti).

2. Veri


Sentetik gözlem verisi, ödev dökümanındaki değerlerle üretildi: $\mu_{\text{gerçek}} = 150.0$, $\sigma_{\text{gerçek}} = 10.0$, $n = 50$, `np.random.seed(42)`. Bu, $N(150, 10^2)$ dağılımından 50 bağımsız çekim anlamına gelir. Çekilen örneklemin **ortalaması 147.75**, **standart sapması 9.34**'tür — bu değerler, Bayesyen modelimizin hangi bölgeye yoğunlaşmayı öğrenmesi gerektiğine dair klasik (frekansçı) sezgiyi verir. Modelimiz doğru çalışıyorsa posterior medyanları bu değerlere yakın, gerçek değerler ise %95 güven aralığının içinde kalmalıdır.



Şekil 1. Sentetik gözlem verisinin histogramı. Kırmızı çizgi gerçek μ , mavi kesik çizgi örneklem ortalamasıdır.

3. Yöntem


Likelihood: Gözlemlerin Gaussian dağılımından bağımsız çekildiği varsayılp log-likelihood $-\frac{1}{2} \sum \left[\frac{(x-\mu)^2}{\sigma^2} + \log(2\pi\sigma^2) \right]$ olarak kodlandı. **Prior:** $\mu \in (0, 300)$ ve $\sigma \in (0, 50)$ üzerinde uniform — geniş ve informative değil. **Örnekleme:** 32 paralel walker, 2000 adım, ilk 500 adım burn-in, 15 adımda bir thinning. Ortalama kabul oranı 0.56. Toplam posterior örnek sayısı ~3200.



Şekil 2. MCMC trace plot. Zincirlerin burn-in sonrası (gri çizginin sağ) gerçek değerler civarında stabil dalgalanması sağlıklı yakınsamanın göstergesidir.

4. Sonular — Corner Plot ve Tablo

Posterior Corner Plot — Geniř Prior, n=50



řekil 3. Posterior daėılımının corner plot gsterimi. Üstte μ 'nın, sağda σ 'nın marjinal daėılımları; sol altta eklem daėılım. Kırmızı çizgiler gerek deėerler; kesik siyah çizgiler %16/%50/%84 yüzdelikleri.

4.1 Parametre Karřılařtırma Tablosu (Ödev 5.1)

Deėiřken	Gerek	Median	Alt (%16)	Üst (%84)	Mutlak Hata
μ (Parlaklık)	150.0	147.769	146.426	149.075	2.231
σ (Hata Payı)	10.0	9.466	8.586	10.516	0.534

%95 gven aralıkları: $\mu \in [145.14, 150.51]$ — gerek deėer 150.0 aralık iinde. $\sigma \in [7.93, 11.71]$ — gerek deėer 10.0 aralık iinde. Model **iyi kalibre edilmiř**.


Pearson korelasyonu $\rho(\mu, \sigma) = -0.010$ — pratik olarak baėımsızlık. Corner plot'ta eklem daėılım dik duruyor.

5. Analiz Soruları

5.1 Prior Etkisi (Ödev Sorusu 6.1)

μ için priori **(100, 110)** bandına daralttığımızda — yani gerçek değerin (150) tamamen dışına — modelin davranışı dramatik biçimde bozulur:

Senaryo	μ median	σ median	Yorum
Geniş prior (doğru)	147.77	9.47	Gerçek değerlere yakın
Dar prior (yanlış)	109.44	40.15	μ prior sınırına sıkıştı, σ şişti




Şekil 4. Geniş ve dar prior altında μ ve σ posterior dağılımları.

Yorum: Yanlış ve dar bir prior, Bayes Teoremi'nde likelihood'u ezer. Model gerçek $\mu=150$ 'ye gidemez çünkü prior bu bölgeye sıfır olasılık atar. Sistem bu uyumsuzluğu σ 'yu şişirerek çözmeye çalışır — çünkü yanlış μ değeriyle veriyi açıklamak için çok büyük bir gürültüye ihtiyaç duyar. Bu, **prior-likelihood gerilimi**'nin klasik örneğidir: informative olmayan geniş priorlar, veri miktarı yeterli olduğunda genellikle daha güvenlidir. Informative priorları ancak güçlü bilimsel gerekçeler varsa kullanmak gerekir (örn. sigma fiziksel olarak negatif olamaz).

5.2 Veri Miktarı Etkisi (Ödev Sorusu 6.2)

Gözlem sayısını 50'den 5'e düşürdüğümüzde posterior dağılımları belirgin biçimde genişler:

Parametre	Genişlik (n=50)	Genişlik (n=5)	Oran
μ posterior [%16-%84]	2.65	8.65	3.27×
σ posterior [%16-%84]	1.93	9.15	4.74×
Teorik beklenti $\sqrt{(50/5)}$	—	—	3.16×



Şekil 5. $n=50$ ve $n=5$ için posterior dağılımların karşılaştırması.

Yorum: Posterior genişliği yaklaşık **3.3×** ve **4.7×** arttı — teorik beklenti olan $\sqrt{(50/5)} \approx 3.16\times$ ile uyumlu. Bu, Gaussian likelihood için ortalamanın standart hatasının $\sigma/\sqrt{n}$ ile küçüldüğü klasik sonucun Bayesyen karşılığıdır. **Bayesyen yaklaşımın avantajı** burada çok belirgindir: az veriyle de bir tahmin üretir, fakat bu tahmine eşlik eden posterior dağılımı *çok daha geniştir* — yani model bize '**ne kadar emin olduğumuzu**' **dürüstçe raporlar**. Frekansçı p-değerleri az veride yanıltıcı olur; Bayesyen posterior bize tam olasılık dağılımını verir.

Soru 6.2'nin Hassasiyet alt-sorusuna cevap: μ için %68 posterior genişliği 2.65, σ için 1.93. Göreli olarak μ 'nun tahmini çok daha kesindir ($\mu: \pm 1.32/150 \approx \%0.9$, $\sigma: \pm 0.97/10 \approx \%9.7$). Nedeni: ortalamanın standart hatası $\sigma/\sqrt{n} \approx 1.41$ iken varyansın $\sigma \cdot \sqrt{2/(n-1)} \approx 2.02$. Varyansı öğrenmek, verinin ikinci momentini (saçılmasının saçılmasını) öğrenmeyi gerektirir — aynı n için bu daha zor bir istatistiksel iştir. n arttıkça iki belirsizlik de küçülür ama σ 'ninkisi her zaman μ 'nunkinden daha yavaş azalır.

5.3 Olasılıksal Korelasyon Analizi (Ödev Sorusu 6.3)

Corner plot'taki eklem dağılıma bakıldığında dağılımın **daire şeklinde** olduğu ve eksenlere hizalı durduğu görülür. Sayısal olarak Pearson korelasyonu **$\rho = -0.010$** (≈ 0). Bu, μ ve σ tahminlerinin posterior'da birbirinden **bağımsız** olduğunu söyler. Gaussian likelihood'da bu matematiksel bir sonuçtur: örneklem ortalaması ($\bar{x}$) ve örneklem varyansı (s^2) bağımsız yeterli istatistiklerdir (Fisher bilgi matrisi diyagonaldir). Yani bir parametredeki belirsizlik diğerine 'sızmaz' — μ 'yu bilmek σ tahminini daraltmaz ve tersi. Daha karmaşık modellerde (örn. lineer regresyon) eğim ve kesişim parametreleri tipik olarak korelasyonlu olur ve corner plot'ta eğik bir elips görürüz.

6. Sonuç

Bayesyen + MCMC yöntemi, gürültülü 50 gözlemden gerçek parlaklığı %1.5 görelî hatayla, gerçek gürültüyü %5.3 görelî hatayla yakaladı; ve her iki gerçek değer de %95 güven

aralığının içinde kaldı. Dar prior deneyi informative olmayan geniş priorların veri yeterli olduğunda neden tercih edildiğini somut olarak gösterdi. $n=5$ deneyi ise Bayesyen yöntemin az veri altında bile *tahmin + tam belirsizlik raporu* sunabildiğini doğruladı — bu yüzden astronomide altın standarttır.